



## 7.3 奇异值分解



## 7.3 奇异值分解

### 回顾：正交矩阵

**定义** 如果  $n$  阶矩阵  $A$  满足  $A^T A = I$ ,  
即  $A^{-1} = A^T$ , 则  $A$  称之为正交矩阵。



$A$  为正交矩阵  $\Leftrightarrow$

$A$  的列向量都是单位向量，且两两正交

$$\begin{pmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_n^T \end{pmatrix} (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n) = I \Rightarrow \mathbf{a}_i^T \mathbf{a}_j = \begin{cases} 1, & \text{当 } i = j, \\ 0, & \text{当 } i \neq j \end{cases} \quad (i, j = 1, 2, \dots, n),$$


**单位向量**

**两两正交**



## 7.3 奇异值分解

### 回顾：四个子空间





## 7.3 奇异值分解

### 回顾：相似矩阵和相似变换

#### 定义

设  $A, B$  都是  $n$  阶矩阵，若有可逆矩阵  $P$ ，使  $P^{-1}AP = B$ ，则称  $B$  是  $A$  的相似矩阵，或是矩阵  $A$  和  $B$  相似。该运算称为对  $A$  进行相似变换。可逆矩阵  $P$  被称为把  $A$  变成  $B$  的相似变换矩阵。

相似矩阵  
Similar matrix

相似变换  
Similarity transformation

## 7.3 奇异值分解

### 回顾：对称矩阵的性质

$$A = P\Lambda P^{-1}$$

普通情况



$$A = ? \Lambda ?$$

对称矩阵

### 定理

每个对称矩阵都分解成  $A = Q\Lambda Q^T$ ,  $\Lambda$  为包括  $A$  特征值的对角矩阵,  $Q$  的列由  $A$  标准正交的特征向量组成。

$$A = Q\Lambda Q^{-1} = Q\Lambda Q^T, Q^{-1} = Q^T$$

## 7.3 奇异值分解

### 什么是SVD?

$n \times n$

$$A = P\Lambda P^{-1}$$

普通情况



$$A = Q\Lambda Q^T$$

对称矩阵

$m \times n$

$$A = U\Sigma V^T$$

$m \times n$

$m \times m$

$m \times n$

$n \times n$



## 7.3 奇异值分解

(1) SVD 产生基本子空间中的含若干  $\mathbf{v}$  向量和  $\mathbf{u}$  向量的标准正交基


(2)  $\Rightarrow \mathbf{A}$  转换成对角矩阵  $\Sigma$ , 并满足  $\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i$ :  $\sigma_i$  为奇异值

(3) 两基对角化  $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$  信息多于  $\mathbf{A} = \mathbf{X}\mathbf{\Lambda}\mathbf{X}^{-1}$

$$(4) \mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T = \mathbf{u}_1\sigma_1\mathbf{v}_1^T + \cdots + \mathbf{u}_r\sigma_r\mathbf{v}_r^T$$

$$\mathbf{U} = \begin{pmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_r & \mathbf{u}_{r+1} & \cdots & \mathbf{u}_m \end{pmatrix}, \mathbf{V} = \begin{pmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_r & \mathbf{v}_{r+1} & \cdots & \mathbf{v}_n \end{pmatrix}$$

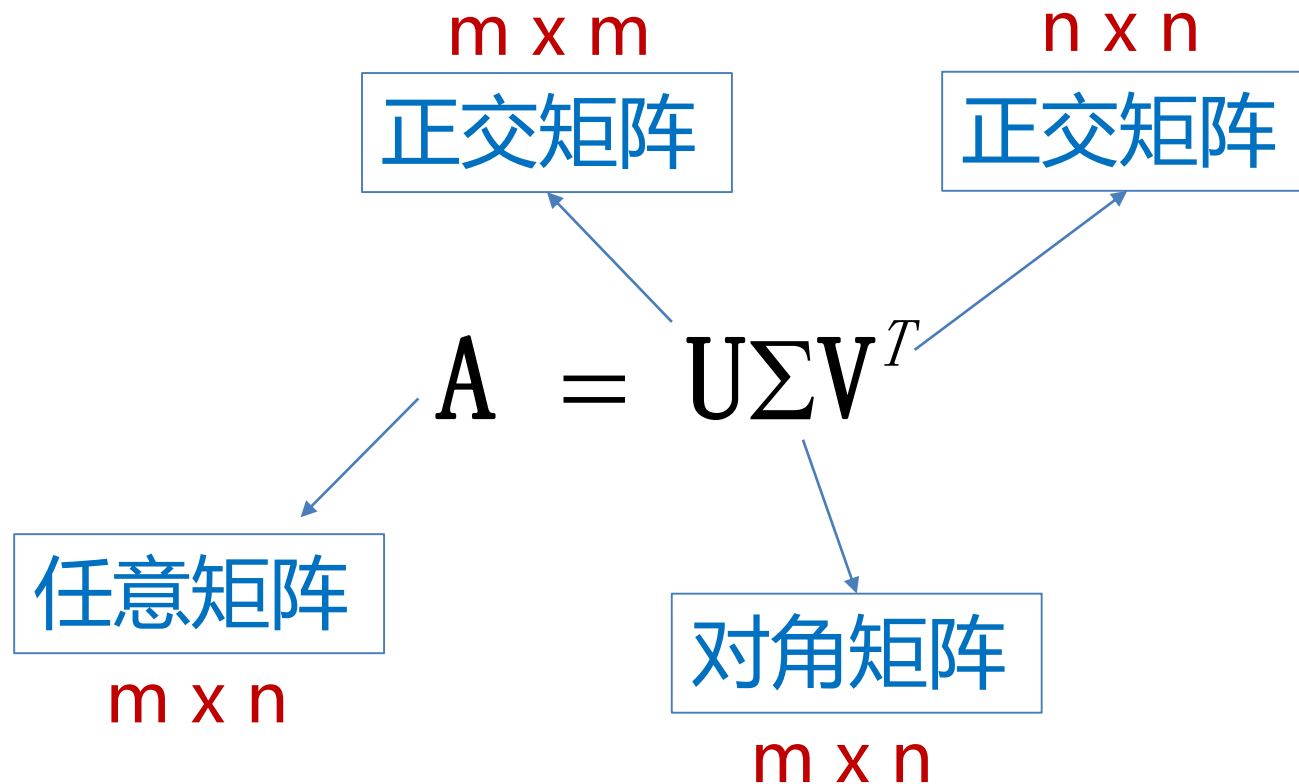
## 7.3 奇异值分解








## 7.3 奇异值分解




## 7.3 奇异值分解

### 如何获得SVD?

行空间



列空间



$$\begin{aligned}\sigma_1 \mathbf{u}_1 &= A\mathbf{v}_1 \\ \sigma_2 \mathbf{u}_2 &= A\mathbf{v}_2 \\ &\dots\end{aligned}$$

一组正交基



另一组正交基



## 7.3 奇异值分解

如何获得SVD?

... → 矩阵表达式

$$A \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_r \end{pmatrix} = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_r \end{pmatrix} \begin{pmatrix} \sigma_1 & & & 0 \\ & \ddots & & \\ & & \ddots & \\ 0 & & & \sigma_r \end{pmatrix}$$



$$AV_r = U_r \Sigma_r$$

$m \times n$        $n \times r$        $m \times r$        $r \times r$

## 7.3 奇异值分解

### 如何获得SVD?

$$A \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_r \end{pmatrix} = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_r \end{pmatrix} \begin{pmatrix} \sigma_1 & & 0 \\ & \ddots & \\ 0 & & \sigma_r \end{pmatrix}$$



$$A \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_r & \mathbf{v}_{r+1} & \cdots & \mathbf{v}_n \end{pmatrix} = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_r & \mathbf{u}_{r+1} & \cdots & \mathbf{u}_m \end{pmatrix} \begin{pmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & \ddots & \\ & & & & 0 \end{pmatrix}$$

$$AV = U\Sigma$$

Diagram illustrating the dimensions of the matrices in the equation  $AV = U\Sigma$ :

- $A$  is  $m \times n$
- $V$  is  $n \times n$
- $U$  is  $m \times m$
- $\Sigma$  is  $m \times n$



## 7.3 奇异值分解

如何获得SVD?

$$AV = U\Sigma \quad \Rightarrow \quad AVV^{-1} = U\Sigma V^{-1} = U\Sigma V^T$$

**V 标准正交矩阵**

$$A = U\Sigma V^T$$

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T \mathbf{U}^T \mathbf{U} \Sigma V^T = V\Sigma^T \Sigma V^T$$

$$\sigma_i^2 = \lambda_i \text{ of } A^T A$$



## 7.3 奇异值分解

### 例1

将矩阵  $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$  奇异值分解。

### 解

$$A^T A = \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix} \Rightarrow \sigma_1^2 = \lambda_1 = 45, \quad \sigma_2^2 = \lambda_2 = 5$$

$$\begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 45 \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = 5 \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \quad (\text{注: 标准正交})$$

## 7.3 奇异值分解

解

.....

$$A\mathbf{v}_1 = \sigma_1\mathbf{u}_1 \Rightarrow \mathbf{u}_1 = \frac{A\mathbf{v}_1}{\sigma_1} = \frac{\begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}}{\sqrt{45}} = \frac{1}{\sqrt{90}} \begin{pmatrix} 3 \\ 9 \end{pmatrix} = \frac{1}{\sqrt{10}} \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

$$A\mathbf{v}_2 = \sigma_2\mathbf{u}_2 \Rightarrow \mathbf{u}_2 = \frac{A\mathbf{v}_2}{\sigma_2} = \frac{\begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}}{\sqrt{5}} = \frac{1}{\sqrt{10}} \begin{pmatrix} -3 \\ 1 \end{pmatrix}$$

$$\Rightarrow A = U\Sigma V^T \text{ with } U = \frac{1}{\sqrt{10}} \begin{pmatrix} 1 & -3 \\ 3 & 1 \end{pmatrix}, \Sigma = \begin{pmatrix} \sqrt{45} & 0 \\ 0 & \sqrt{5} \end{pmatrix}, V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$



## 7.3 奇异值分解


伪逆矩阵

方阵

$A_{n \times n}$  可逆  $\Rightarrow$  存在  $A^{-1}$

一般矩阵

$A_{m \times n}$  ?可逆?  $\Rightarrow$  存在  $A_{n \times m}^+$


$$A^+ = V \Sigma^+ U^T = \begin{pmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_r & \cdots & \mathbf{v}_n \end{pmatrix} \begin{pmatrix} \sigma_1^{-1} & & & \\ & \ddots & & \\ & & \sigma_r^{-1} & \\ & & & 0 \end{pmatrix} \begin{pmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_r & \cdots & \mathbf{u}_m \end{pmatrix}^T$$


$$A = U \Sigma V^T$$



# SVD 分解 → 图像处理

## Matlab 代码

```
a=imread( 'xxx.png');
```

```
a=double(a);
```

```
[U S V]=svd(a);
```

① 10




②

50



③ 100



```
re=U(:,1:50)*S(1:50,1:50)*S(:,1:50)';
```

```
figure;
```

```
imshow(mat2gray(re));
```

```
imwrite(mat2gray(re),'xxx50.jpg')
```

```
re=U(:,1:10)*S(1:10,1:10)*V(:,1:10)';
```

```
figure;
```

```
imshow(mat2gray(re));
```

```
imwrite(mat2gray(re),'xxx10.jpg')
```


```
re=U(:,1:100)*S(1:100,1:100)*V(:,1:100)';
```

```
figure;
```


```
imshow(mat2gray(re));
```

```
imwrite(mat2gray(re),'xxx100.jpg')
```


# SVD 分解 → 图像处理




1




2




5




10



20



50



100



- LAPACK — Linear Algebra PACKage
- SVD 的应用领域
  - 图像处理：压缩、去噪
  - 科学与工程参数估算、反问题
  - 金融、化工(主成分分析 PCA)
  - 信号处理
  - 机器学习
  - 气象学
  - .....

## 7.4 条件优化



## 7.4 条件优化

### 例1

求  $Q(x) = 9x_1^2 + 4x_2^2 + 3x_3^2$ , 在限制条件  $\mathbf{x}^T \mathbf{x} = 1$  下的最大值和最小值。

### 解

由于  $x_2^2$  和  $x_3^2$  是非负的, 注意到

$$4x_2^2 \leq 9x_2^2 \quad \text{和} \quad 3x_3^2 \leq 9x_3^2$$

所以当  $x_1^2 + x_2^2 + x_3^2 = 1$  时,

$$\begin{aligned} Q(x) &= 9x_1^2 + 4x_2^2 + 3x_3^2 \\ &\leq 9x_1^2 + 9x_2^2 + 9x_3^2 \\ &= 9(x_1^2 + x_2^2 + x_3^2) \\ &= 9 \end{aligned}$$



## 7.4 条件优化

**例1** 求  $Q(x)=9x_1^2 + 4x_2^2 + 3x_3^2$ , 在限制条件  $x^T x = 1$  下的最大值和最小值。

**解** 因此当  $x$  是单位向量时,  $Q(x)$  的最大值不超过9. 更进一步, 当  $x = (1, 0, 0)$  时,  $Q(x) = 9$ . 从而9是  $Q(x)$  在  $x^T x = 1$  条件下的最大值。为求出  $Q(x)$  的最小值, 注意到

$$9x_1^2 \geq 3x_1^2, 4x_2^2 \geq 3x_2^2$$

因此当  $x_1^2 + x_2^2 + x_3^2 = 1$  时,

$$Q(x) \geq 3x_1^2 + 3x_2^2 + 3x_3^2 = 3(x_1^2 + x_2^2 + x_3^2) = 3$$

当  $x_1 = 0, x_2 = 0, x_3 = 1$  时,  $Q(x) = 3$ , 从而3是  $Q(x)$  在  $x^T x = 1$  条件下的最小值。



## 7.4 条件优化

### 例2

设  $A = \begin{bmatrix} 3 & 0 \\ 0 & 7 \end{bmatrix}$ , 当  $x$  属于  $R^2$  时,  $Q(x) = x^T A x$ , 图1是  $Q$  的图形表示,

图2表示圆柱体内的一部分, 圆柱与曲面的截面是点集  $(x_1, x_2, z)$ , 表示在  $x_1^2 + x_2^2 = 1$  情况下的  $z = Q(x_1, x_2)$ . 这些点的高度值是  $Q(x)$  的约束值, 从几何意义上来看, 条件优化问题确定的是截面曲线上最高点和最低点的位置。

## 7.4 条件优化




FIGURE 1  $z = 3x_1^2 + 7x_2^2$ .




FIGURE 2 The intersection of  $z = 3x_1^2 + 7x_2^2$  and the cylinder  $x_1^2 + x_2^2 = 1$ .

曲线上的两个最高点在 $x_1x_2$ 平面之上7个单位，出现在点 $x=0$ 和 $x=\pm 1$ 处，这些点对应 $A$ 的特征值7和特征向量 $x=(0,1)$ ,  $-x=(0,-1)$ .



## 7.4 条件优化




FIGURE 1  $z = 3x_1^2 + 7x_2^2$ .




FIGURE 2 The intersection of  $z = 3x_1^2 + 7x_2^2$  and the cylinder  $x_1^2 + x_2^2 = 1$ .

类似的，曲线上的两个最低点在 $x_1x_2$ 平面之上3 个单位，它们对应特征值3 和特征向量 $(1, 0)$  和 $(-1, 0)$ .



## 7.4 条件优化

### 定理1

设 $A$ 是对称矩阵, 且

$$m = \min\{x^T A x : \|x\| = 1\}, \quad M = \max\{x^T A x : \|x\| = 1\}$$

那么 $M$ 是 $A$  的最大特征值 $\lambda_1$ ,  $m$ 是 $A$  的最小特征值, 如果 $x$ 是对应 $M$  的单位特征向量 $u_1$ , 那么 $x^T A x$  的值等于 $M$ , 如果 $x$ 是对应 $m$  的单位特征向量,  $x^T A x$  的值等于 $m$ .



## 7.4 条件优化

### 例3

设  $A = \begin{bmatrix} 3 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 4 \end{bmatrix}$ , 求二次型  $x^T A x$  在限制条件  $x^T x = 1$  下的最大值,

且求一个可以取到该最大值的单位向量。

**解**

由定理1, 我们只需求出A的最大特征值, 其多项式是:

$$0 = -\lambda^3 + 10\lambda^2 - 27\lambda + 18 = -(\lambda - 6)(\lambda - 3)(\lambda - 1)$$

最大特征值为6.

限制条件下  $x^T A x$  的最大值, 可以在特征值  $\lambda = 6$  对应得单位特征向量  $x$  处获得, 解  $(A - 6I)x = 0$ , 我们可得向量



## 7.4 条件优化

### 例3

设  $A = \begin{bmatrix} 3 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 4 \end{bmatrix}$ , 求二次型  $x^T A x$  在限制条件  $x^T x = 1$  下的最大值,

且求一个可以取到该最大值的单位向量。

**解**

我们可得特征向量:

$$\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \text{和} \quad u_1 = \begin{bmatrix} 1/\sqrt{3} \\ 1/\sqrt{3} \\ 1/\sqrt{3} \end{bmatrix}$$

## 7.4 条件优化



Next

考虑  $x^T A x$  的值，此时， $x$  是单位向量且与定理1中提到的特征向量  $u_1$  正交。



## 7.4 条件优化

### 定理2

设 $A$ ,  $\lambda_1$ 和 $u_1$ 如定理1所示, 在如下条件的限制下

$$x^T x = 1, \quad x^T u_1 = 0$$

$x^T A x$ 的最大值是第二大特征值 $\lambda_2$ , 且这个最大值可以在 $x$ 是对应 $\lambda_2$ 的特征向量 $u_2$ 处达到。



Next

例4给出对角阵情形下的  
证明思路



## 7.4 条件优化

### 例4

求 $9x_1^2 + 4x_2^2 + 3x_3^2$ 的最大值，其限制条件是 $x^T x = 1$ 和 $x^T u_1 = 0$ ，这里 $u_1 = (1, 0, 0)$ 。注意到 $u_1$ 是二次型对应的矩阵的最大特征值 $\lambda = 9$ 对应的单位特征向量。

### 解

如果 $x$ 的坐标为 $x_1, x_2, x_3$ ，那么限制 $x^T u_1 = 0$  简单意味着 $x_1 = 0$ ，对这样一个单位向量， $x_2^2 + x_3^2 = 1$  且

$$\begin{aligned} 9x_1^2 + 4x_2^2 + 3x_3^2 &= 4x_2^2 + 3x_3^2 \\ &\leq 4x_2^2 + 4x_3^2 \\ &= 4(x_2^2 + x_3^2) = 4 \end{aligned}$$



## 7.4 条件优化

### 例4

求  $9x_1^2 + 4x_2^2 + 3x_3^2$  的最大值，其限制条件是  $x^T x = 1$  和  $x^T u_1 = 0$ ，这里  $u_1 = (1, 0, 0)$ 。注意到  $u_1$  是二次型对应的矩阵的最大特征值  $\lambda = 9$  对应的单位特征向量。

### 解

在这样的限制条件下，二次型的最大值不超过4，且这个最大值可在  $x = (0, 1, 0)$  处达到，而这就是二次型对应矩阵的第二大特征值对应的特征向量。





## 7.4 条件优化

### 定理3

设 $A$ 是 $n$ 阶对称矩阵, 且其正交对角化为 $A = PDP^{-1}$ , 将对角矩阵 $D$ 上的元素重新排列, 使得 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ , 且 $P$ 的列是其对应的单位特征向量 $u_1, \cdots, u_n$ , 那么对 $k = 2, \cdots, n$  时, 在以下限制条件下

$$x^T x = 1, \quad x^T u_1 = 0, \cdots, x^T u_{k-1} = 0$$

$x^T A x$ 的最大值是特征值 $\lambda_k$ , 且这个最大值在 $x = u_k$  处可以达到。



---

Q & A



## 7.3 奇异值分解

### 如何获得SVD?

U 是否为标准正交矩阵?

$i \neq j :$

$$\begin{aligned} \mathbf{u}_i^T \mathbf{u}_j &= \left( \frac{\mathbf{A} \mathbf{v}_i}{\sigma_i} \right)^T \left( \frac{\mathbf{A} \mathbf{v}_j}{\sigma_j} \right) = \frac{\mathbf{v}_i^T \mathbf{A}^T \mathbf{A} \mathbf{v}_j}{\sigma_i \sigma_j} \\ &= \frac{\mathbf{v}_i^T \mathbf{V} \Sigma^T \Sigma \mathbf{V}^T \mathbf{v}_j}{\sigma_i \sigma_j} = \frac{\mathbf{e}_i^T \Sigma^T \Sigma \mathbf{e}_j}{\sigma_i \sigma_j} = \text{ZERO} \end{aligned}$$

...  $\mathbf{u}_i$  是  $\mathbf{A} \mathbf{A}^T$  的特征向量



## 6.2 正交集

### 定义

如果  $m \times n$  阶矩阵  $U$  的向量是标准正交的

$$\Leftrightarrow U^T U = I.$$

### 证明

设  $U = \begin{bmatrix} u_1 & u_2 & u_3 \end{bmatrix}$ , 且  $u_i \in \mathbb{R}^m, i = 1, 2, 3$ . 那么,

$$U^T U = \begin{bmatrix} u_1^T \\ u_2^T \\ u_3^T \end{bmatrix} \begin{bmatrix} u_1 & u_2 & u_3 \end{bmatrix} = \begin{bmatrix} u_1^T u_1 & u_1^T u_2 & u_1^T u_3 \\ u_2^T u_1 & u_2^T u_2 & u_2^T u_3 \\ u_3^T u_1 & u_3^T u_2 & u_3^T u_3 \end{bmatrix}$$

$U$  是正交矩阵当且仅当

$$u_1^T u_2 = u_2^T u_1 = 0, u_1^T u_3 = u_3^T u_1 = 0, u_2^T u_3 = u_3^T u_2 = 0$$

$$u_1^T u_1 = 1, u_2^T u_2 = 1, u_3^T u_3 = 1, \text{ 即 } U^T U = I$$