



中山大學
SUN YAT-SEN UNIVERSITY



国家超级计算广州中心
NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

并行程序设计 with 算法 (实验)

Lab0-环境配置与串行矩阵乘法

吴迪

中山大学 计算机学院

◉ 内容

- 配置环境
- 实现串行矩阵乘法
- 优化串行矩阵乘法
- 对比及初步性能分析

◉ 目标

- 熟悉Linux编程及编译环境 (shell, vim, gcc, gdb)
- 掌握基本矩阵乘法实现方式

- 1. 下载安装虚拟机软件（推荐VMware或VirtualBox）
 - VMware: <https://www.vmware.com/products/workstation-pro/workstation-pro-evaluation.html>
 - VirtualBox: <https://www.virtualbox.org/wiki/Downloads>
- 2. 下载Ubuntu 18.04镜像文件：
 - <http://releases.ubuntu.com/18.04/>

◉ 安装Ubuntu

- 创建虚拟机实例，设置CPU核、内存、硬盘容量
- 在虚拟光驱中加载Ubuntu镜像文件 (.iso) ， 并安装操作系统

◉ 安装OpenMPI 和 vim

- 启动系统，在命令行终端安装OpenMPI
 - `sudo apt-get update`
 - `sudo apt-get install libopenmpi-dev -y`
 - `sudo apt-get install vim -y`

- Intel Math Kernel Library (MKL) 是英特尔公司推出的一款高性能数学库
 - 旨在提供数值计算、线性代数、信号处理和统计分析等方面的优化函数和子程序
 - MKL库针对英特尔处理器架构进行了高度优化，可以充分发挥英特尔处理器的性能优势
 - 除了数学函数之外，Intel MKL库还提供了一些优化工具，例如性能分析器和线程构建器



• Intel oneAPI Math Kernel Library (MKL) 命令行安装

// 下载intel 公钥

```
sudo wget https://apt.repos.intel.com/intel-gpg-keys/GPG-PUB-KEY-INTEL-SW-PRODUCTS.PUB
```

```
sudo apt-key add GPG-PUB-KEY-INTEL-SW-PRODUCTS.PUB
```

// Add the APT Repository

```
sudo sh -c 'echo deb https://apt.repos.intel.com/mkl all main >  
/etc/apt/sources.list.d/intel-mkl.list'
```

```
sudo apt-get update
```

// Install

```
sudo apt-get install intel-mkl-64bit-2020.2
```

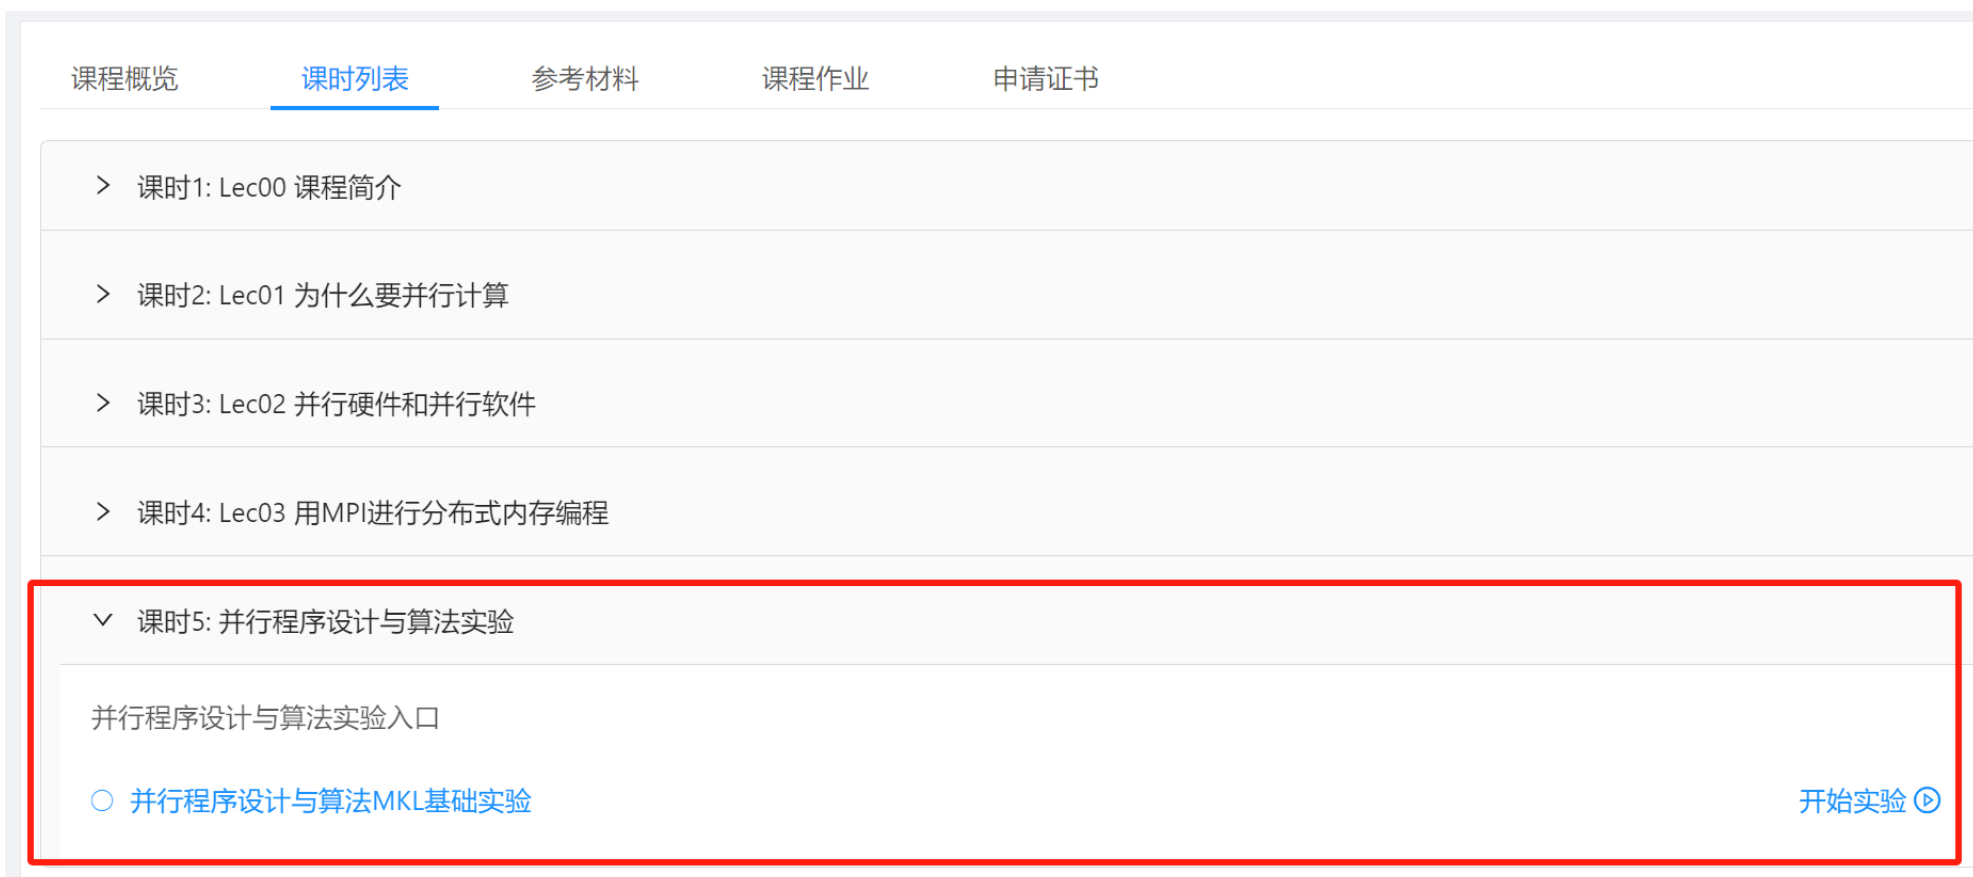
```
source /opt/intel/compilers_and_libraries_2020/linux/mkl/bin/mklvars.sh  
intel64 ilp64
```

```
. /opt/intel/bin/compilervars.sh intel64
```


```
gcc example.c -lmkl_rt
```

```
./a.out
```

- 在“课时5：并行程序设计 with 算法实验”中，提供了预装MKL和openmpi的基础实验环境
 - MKL配置指引 (user-guide.txt) 和示例代码 (example.c)
 - 用户数据可以保存在目录 ~/data/中



- 对于输入矩阵 A, B 计算其乘积 $C = A \cdot B$
 - 对于 C 中每个元素, 计算 $C_{ij} = \sum_{k=1}^m A_{ik} \cdot B_{kj}$
 - 共需 $n \times p$ 次向量内积
 - 每次内积需 m 次乘法及 $m - 1$ 次加法



- 类别1：实现优化（从计算机体系结构角度优化）
 - 调整编译器选项
 - 设置优化级别、编译器标志等
 - 调整循环顺序
 - 循环展开等
 - 参考资料
 - <https://jackwish.net/2019/gemm-optimization.html>
 - https://blog.csdn.net/weixin_43614211/article/details/122105195
- 类别2：算法优化（从数学角度优化）
 - Strassen算法, Coppersmith-Winograd算法

编译优化级别

- **-O0 (不优化)**：默认的编译选项，表示不进行任何优化。
- **-O (优化)**：这个选项会开启一些基本优化，是 **-O1** 的一个简化版本，通常用于快速测试编译器是否能够生成有效的代码。
- **-O1**：这个级别会开启一系列的优化，包括循环展开、函数内联、常量表达式消除、死代码消除等
- **-O2**：这个级别会开启更多的优化，包括全局优化、自动对齐、软件流水线等。
- **-O3**：这个级别会开启所有可用的优化，除了那些可能会增加编译时间的优化。这包括 **-O2** 中的所有优化，以及一些额外的优化，如内联函数的优化、对数组访问的优化等。
- **-Ofast**：这个选项会开启所有优化，包括那些可能会增加编译时间的优化。这通常会生成最快的代码，但可能会牺牲代码的大小和可读性。
- **-Os (最紧凑大小)**：这个选项会优化代码的大小，而不是性能。编译器会尽可能生成小的代码，通常用于嵌入式系统或资源受限的环境。

编译优化标志

- **-ffast-math**：这个选项会关闭某些数学函数的严格准确性检查，以换取更高的性能，对浮点运算有帮助
- **-funroll-loops**：这个选项会展开循环，以减少循环控制的开销，对循环嵌套的程序有性能提升作用。
- **-fomit-frame-pointer**：这个选项用于决定是否在汇编代码中包含帧指针。帧指针是一个在函数调用时保存当前栈帧地址的寄存器。如果不使用帧指针，那么函数调用的开销会更小

- 编译命令示例:

```
gcc -O3 -fomit-frame-pointer myprogram.c -o myprogram
```

O3级别优化

不在汇编代码中包含帧指针

- 调整内外循环的顺序可能会影响代码的性能
 - 尤其是在涉及多维数组或矩阵操作时，这种影响通常与数据的访问模式和缓存利用率有关
 - 假设CPU缓存是按照行优先的方式工作的，那么行优先遍历可能会比列优先遍历更加高效，因为它减少了缓存失效的次数

```
// 行优先遍历
void row_major_traversal() {
    for (int i = 0; i < N; ++i) {
        for (int j = 0; j < N; ++j) {
            row_major_sum += matrix[i][j];
        }
    }
}
```

```
// 列优先遍历
void col_major_traversal() {
    for (int j = 0; j < N; ++j) {
        for (int i = 0; i < N; ++i) {
            col_major_sum += matrix[i][j];
        }
    }
}
```

- 通过减少循环终止条件检查和循环索引更新的次数来提高代码性能
 - 这样可以减少循环的迭代次数、减少分支预测错误的可能性，从而提高代码的运行效率。

```
void loop_unrolling_example(int *arr, int size) {  
    for (int i = 0; i < size; i += 4) {  
        arr[i] += 1;  
        arr[i+1] += 1;  
        arr[i+2] += 1;  
        arr[i+3] += 1;  
    }  
}
```

• Divide and conquer 算法 – 便于并行

– 直接思路：将每个矩阵分为4份

- 8次小矩阵乘法和4次小矩阵加法计算

- 时间复杂度 $T(n) = 8T\left(\frac{n}{2}\right) + O(n^2) = O(n^3)$

– 总计算量完全一致（参考分块计算）

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} e & f \\ g & h \end{pmatrix} = \begin{pmatrix} ae+bg & af+bh \\ ce+dg & cf+dh \end{pmatrix}$$

A B C

Strassen算法

– 仍然将矩阵A与B分别分为4块

- 如下计算 p_1, p_2, \dots, p_7
- 使用 p_1, p_2, \dots, p_7 更新C中4块子矩阵的值, 好处是?

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} e & f \\ g & h \end{pmatrix} = \begin{pmatrix} p_5+p_4-p_2+p_6 & p_1+p_2 \\ p_3+p_4 & p_1+p_5-p_3-p_7 \end{pmatrix}$$

A B C

$$\begin{aligned} p_1 &= a(f-h) \\ p_2 &= (a+b)h \\ p_3 &= (c+d)e \\ p_4 &= d(g-e) \end{aligned}$$

$$\begin{aligned} p_5 &= (a+d)(e+h) \\ p_6 &= (b-d)(g+h) \\ p_7 &= (a-c)(e+f) \end{aligned}$$

- **效率分析:** 7次小矩阵乘法与18次小矩阵加法, 加法效率比乘法更高
- **时间复杂度:** $T(n) = 7T\left(\frac{n}{2}\right) + O(n^2) = O(n^{\log_2 7}) = O(n^{2.8074})$

- 验证: $p_5 + p_4 - p_2 + p_6 = (a+d)(e+h) + d(g-e) - (a+b)h + (b-d)(g+h)$
 $= ae + ah + de + dh + dg - de - ah - bh + bg + bh - dg - dh$
 $= ae + bg$

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} e & f \\ g & h \end{pmatrix} = \begin{pmatrix} p_5 + p_4 - p_2 + p_6 & p_1 + p_2 \\ p_3 + p_4 & p_1 + p_5 - p_3 - p_7 \end{pmatrix}$$

A B C

$$p_1 = a(f - h)$$

$$p_2 = (a + b)h$$

$$p_3 = (c + d)e$$

$$p_4 = d(g - e)$$

$$p_5 = (a + d)(e + h)$$

$$p_6 = (b - d)(g + h)$$

$$p_7 = (a - c)(e + f)$$

- 使用Intel MKL算法库来优化代码性能

- 稠密矩阵乘法**cbblas_dgemm**示范代码

- <https://www.intel.com/content/www/us/en/docs/onemkl/tutorial-c/2021-4/multiplying-matrices-using-dgemm.html>

```
double *A, *B, *C;
int m, n, k, i, j;
double alpha, beta;

A = (double *)mk1_malloc( m*k*sizeof( double ), 64 );
B = (double *)mk1_malloc( k*n*sizeof( double ), 64 );
C = (double *)mk1_malloc( m*n*sizeof( double ), 64 );

cbblas_dgemm(CblasRowMajor, CblasNoTrans, CblasNoTrans,
              m, n, k, alpha, A, k, B, n, beta, C, n);
```

Intel oneAPI Math Kernel Library (MKL) – 使用

– 稠密矩阵乘法 **cbblas_dgemm** 示范代码

- <https://www.intel.com/content/www/us/en/docs/onemkl/tutorial-c/2021-4/multiplying-matrices-using-dgemm.html>

```
double *A, *B, *C;
int m, n, k, i, j;
double alpha, beta;

A = (double *)mkl_malloc( m*k*sizeof( double ), 64 );
B = (double *)mkl_malloc( k*n*sizeof( double ), 64 );
C = (double *)mkl_malloc( m*n*sizeof( double ), 64 );

cbblas_dgemm(CblasRowMajor, CblasNoTrans, CblasNoTrans,
             m, n, k, alpha, A, k, B, n, beta, C, n);
```

实现多个版本串行矩阵乘法，并进行对比分析

版本	实现描述	运行时间 (sec.)	相对 加速比	绝对 加速比	浮点性能 (GFLOPS)	峰值性能 百分比
1	Python					
2	C/C++					
3	调整循环顺序					
4	编译优化					
5	循环展开					
6	Intel MKL					

- “相对加速比” 为相对于前一版本的加速比；
- “绝对加速比” 为相对于版本1的加速比；
- “浮点性能”：统计程序里面跑了多少次浮点计算，然后除以运行时间
- “峰值性能百分比” 为当前浮点性能相对于计算设备峰值性能的百分比

Questions?

