半监督图像分类

实验内容

1. 阅读原始论文和相关参考资料，基于 Pytorch 动手实现 FixMatch 半监督图像分类算法，在 CIFAR-10 进行半监督图像分类实验，报告算法在分别使用 40,250, 4000 张标注数据的情况下的图像分类结果
2. 按照原始论文的设置，FixMatch 使用 WideResNet-28-2 作为 Backbone 网络，即深度为 28，扩展因子为 2，使用 CIFAR-10 作为数据集，可以参考现有代码的实现，算法核心步骤不能直接照抄！
3. 使用 TorchSSL 中提供的 FixMatch 的实现进行半监督训练和测试，对比自己实现的算法和 TorchSSL 中的实现的效果

实验过程

一、FixMatch实现

算法步骤

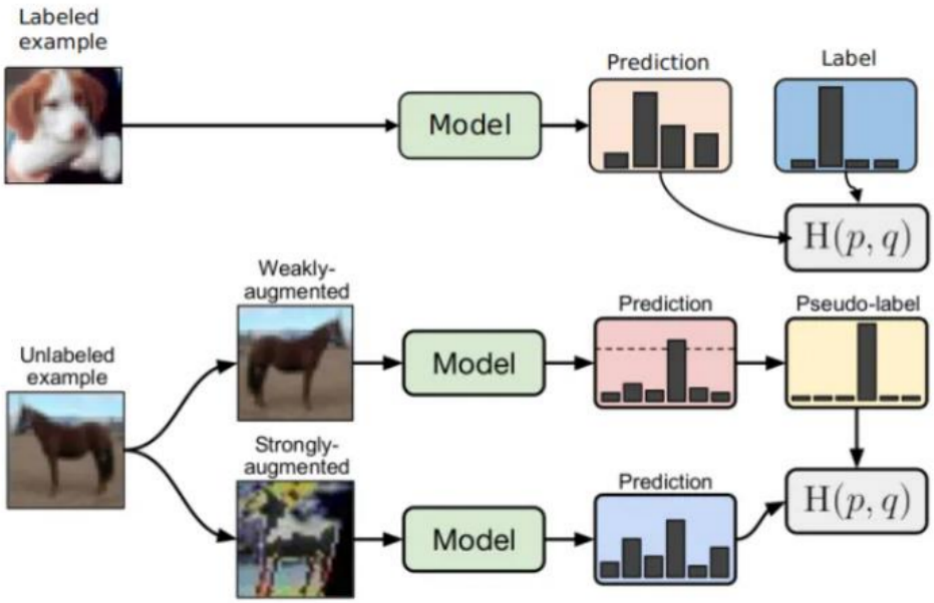

1. **有标签数据训练**：
    - 对于每个有标签数据，计算模型预测与真实标签之间的交叉熵损失。
2. **无标签数据训练**：
    - 数据增强：
        - 对每个无标签数据样本，生成一个弱增强版本和一个强增强版本。
    - 伪标签生成：
        - 将弱增强版本的图像输入模型，获取预测分布。
        - 从预测分布中提取伪标签（即选择概率最高的类别作为伪标签）。
    - 一致性损失计算：
        - 将强增强版本的图像输入模型，获取预测分布。
        - 计算强增强版本的预测分布与伪标签之间的交叉熵损失。
3. **总损失计算和反向传播**：

- 结合有标签数据的交叉熵损失和无标签数据的一致性损失，计算总损失。
- 使用反向传播算法更新模型参数。

核心代码

- 对无标签数据集使用弱增强与强增强:弱扩增与有标签的数据处理方式类似，直接使用翻转和裁剪技术；强扩增还使用了RandAugmentMC 算法进行数据增强

```
# 有标签数据
transform_labeled = transforms.Compose([
    transforms.RandomHorizontalFlip(),
    transforms.RandomCrop(size=32,
                          padding=int(32*0.125),
                          padding_mode='reflect'),
    transforms.ToTensor(),
    transforms.Normalize(mean=cifar10_mean, std=cifar10_std)
])
# 无标签弱增强
self.weak = transforms.Compose([
    transforms.RandomHorizontalFlip(),
    transforms.RandomCrop(size=32,
                          padding=int(32*0.125),
                          padding_mode='reflect')])
# 无标签强增强
self.strong = transforms.Compose([
    transforms.RandomHorizontalFlip(),
    transforms.RandomCrop(size=32,
                          padding=int(32*0.125),
                          padding_mode='reflect'),
    RandAugmentMC(n=2, m=10)])
```

- 关于数据如何输入模型，考虑到如果有标签、无标签弱增强、无标签强增强 3 份数据分别输入网络，在批量归一化中会出现 3 种不同分布，使模型难以拟合，以此采取将 3 种数据混合的方式，使用 `interleave` 和 `de_interleave` 是在一个批次内混合标记数据和无标记数据，以便共同计算批量归一化的统计量，从而提高模型训练的稳定性和效果

```
# 混合输入(a, b, c)->(a/size, size, b, c)->(size, a/size, b, c)->(size * a/size,
b, c)
def interleave(x, size):
    s = list(x.shape)
    return x.reshape([-1, size] + s[1:]).transpose(0, 1).reshape([-1] + s[1:])
# 分离输出 interleave的逆过程
def de_interleave(x, size):
    s = list(x.shape)
    return x.reshape([size, -1] + s[1:]).transpose(0, 1).reshape([-1] + s[1:])
```

- 训练基本框架如下：代码展示有所简化

```
# 获取数据集
labeled_dataset, unlabeled_dataset, test_dataset = DATASET_GETTERS[args.dataset]
(
        args, './data')
# 定义数据加载器
labeled_trainloader = DataLoader(
```

```
    labeled_dataset,
    sampler=train_sampler(labeled_dataset),
    batch_size=args.batch_size,
    num_workers=args.num_workers,
    drop_last=True)
unlabeled_trainloader = DataLoader(
    unlabeled_dataset,
    sampler=train_sampler(unlabeled_dataset),
    batch_size=args.batch_size*args.mu,
    num_workers=args.num_workers,
    drop_last=True)
# 定义优化器
optimizer = optim.SGD(grouped_parameters, lr=args.lr,
                          momentum=0.9, nesterov=args.nesterov)
scheduler = get_cosine_schedule_with_warmup(
        optimizer, args.warmup, args.total_steps)
# 定义迭代器
labeled_iter = iter(labeled_trainloader)
unlabeled_iter = iter(unlabeled_trainloader)
# 进入循环
    # 迭代得到训练数据
    inputs_x, targets_x = labeled_iter.next()
    (inputs_u_w, inputs_u_s), _ = unlabeled_iter.next()
    # 混合输入数据
    inputs = interleave(torch.cat((inputs_x, inputs_u_w, inputs_u_s)),
2*args.mu+1).to(args.device)
    targets_x = targets_x.to(args.device)
    # 分离输出数据
    logits = model(inputs)
    logits = de_interleave(logits, 2*args.mu+1)
    logits_x = logits[:batch_size]
    logits_u_w, logits_u_s = logits[batch_size:].chunk(2)
    # 损失函数cross_entropy
    # 有标签损失:Lx
    Lx = F.cross_entropy(logits_x, targets_x, reduction='mean')
    # 无标签损失:以弱增强输入筛选出可训练数据,再用强增强输出计算损失函数Lu
    pseudo_label = torch.softmax(logits_u_w.detach()/args.T, dim=-1)
    max_probs, targets_u = torch.max(pseudo_label, dim=-1)
    mask = max_probs.ge(args.threshold).float()
    Lu = (F.cross_entropy(logits_u_s, targets_u, reduction='none') *
mask).mean()
    loss = Lx + args.lambda_u * Lu
    # 反向传播
    loss.backward()
    # 更新参数模型
    optimizer.step()
    scheduler.step()
```

- 训练细节
    - `use-ema`：指数移动平均模型，EMA 模型通过对模型参数进行指数加权平均来平滑参数更新过程，从而减少参数更新的波动性，提高模型的泛化能力。

      如果不使用ema模型会出现以下loss为nan的情况

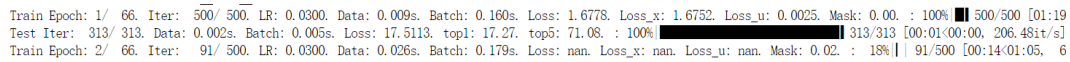

- `weight_decay`:对所有不包含 `bias` 和 `bn` 的参数应用权重衰减，来防止过拟合
- `cosine_schedule_with_warmup`学习策略
  - 预热阶段：在训练开始时，学习率从 0 开始线性增加到预设的基础学习率，这有助于避免大步长更新权重，从而防止在训练初期不稳定。
  - 余弦退火阶段：预热阶段结束后，学习率按照余弦函数的形式逐渐降低,使模型在训练后期更稳定，更好地收敛。

运行结果

```
python train.py --num-labeled 4000 --epochs 500
# 其他参数       default
--epochs         50
--batch-size     32
--lr             0.03
--warmup         0
--mu             7
--threshold      0.95
--lambda-u       1
```

开始运行：

```
(fix) jovyan@jupyter-21307347:~/Fix$ python train.py --num-labeled 4000 --epochs 500
Files already downloaded and verified
06/27/2024 02:27:57 - INFO - __main__ -   {'gpu_id': 0, 'num_labeled': 4000, 'epochs': 500, 'batch_size': 32, 'lr': 0.03, 'warmup': 0,
 'mu': 7, 'lambda_u': 1, 'threshold': 0.95, 'out': 'result', 'resume': '', 'n_gpu': 4, 'device': device(type='cuda', index=0), 'num_cl
asses': 10, 'model_depth': 28, 'model_width': 2, 'num_workers': 4, 'wdecay': 0.0005, 'nesterov': True, 'use_ema': True, 'ema_decay': 0
.999, 'start_epoch': 0, 'eval_step': 224, 'total_steps': 112000}
06/27/2024 02:27:57 - INFO - __main__ -   ***** Running training *****
06/27/2024 02:27:57 - INFO - __main__ -     Task = cifar10@4000
06/27/2024 02:27:57 - INFO - __main__ -     Num Epochs = 500
06/27/2024 02:27:57 - INFO - __main__ -     Batch size = 32
06/27/2024 02:27:57 - INFO - __main__ -     Total optimization steps = 112000
06/27/2024 02:27:57 - INFO - __main__ -    labeled dataset = 4000
06/27/2024 02:27:57 - INFO - __main__ -    unlabeled dataset = 50000
06/27/2024 02:27:57 - INFO - __main__ -    test dataset = 10000
Train Epoch: 1/ 500. Iter:  224/ 224. LR: 0.0300. Data: 0.011s. Batch: 0.199s. Loss: 1.7757. Loss_x: 1.7756. Loss_u: 0.0001. Mask: 0.0
Test Iter:  313/ 313. Data: 0.002s. Batch: 0.005s. Loss: 2.3784. top1: 10.00. top5: 59.74. : 100%|██| 313/313 [00:01<00:00, 202.61it/s]
Train Epoch: 2/ 500. Iter:  224/ 224. LR: 0.0300. Data: 0.018s. Batch: 0.201s. Loss: 1.4881. Loss_x: 1.4841. Loss_u: 0.0039. Mask: 0.0
Test Iter:  313/ 313. Data: 0.002s. Batch: 0.005s. Loss: 2.1759. top1: 16.86. top5: 64.49. : 100%|██| 313/313 [00:01<00:00, 207.62it/s]
Train Epoch: 3/ 500. Iter:  217/ 224. LR: 0.0300. Data: 0.016s. Batch: 0.196s. Loss: 1.3482. Loss_x: 1.3334. Loss_u: 0.0148. Mask: 0.0
```

时间原因只在500epoches中比较不同标注数据量的分类结果对比：

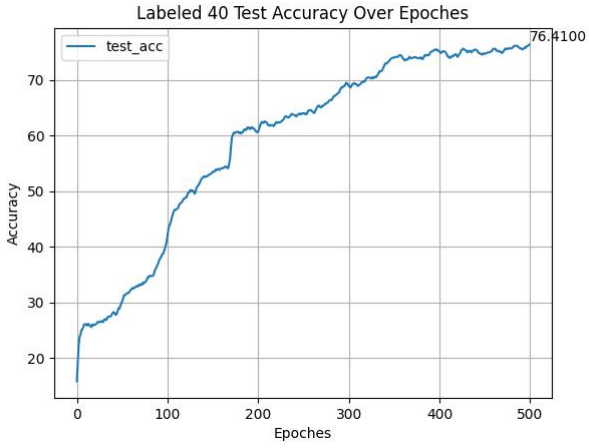

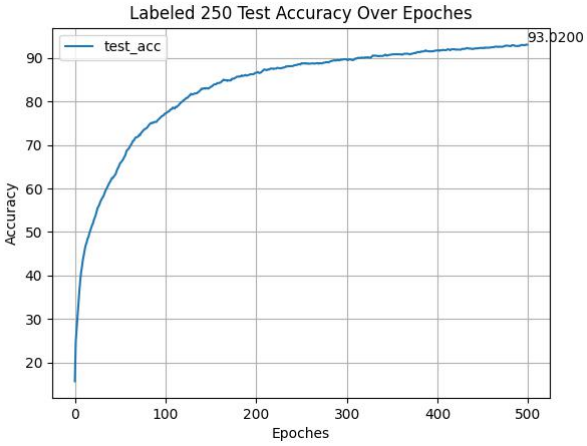

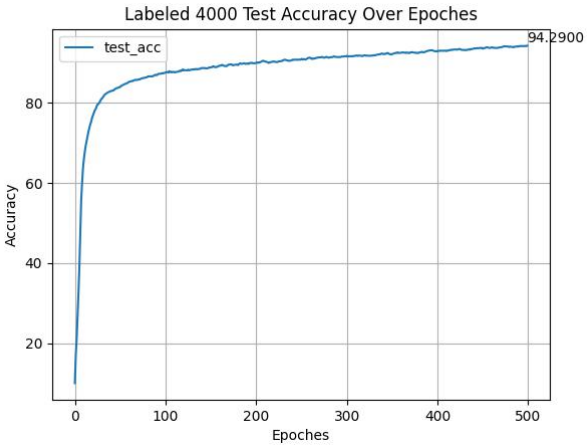

其中有标签数量40在epoches=500内未能收敛，由于运行时间较长，且在之后epoch中未能及时记录运行数据，因此以上图片展示只展示到500个epoches，之后的训练效果可参考下图：标签数量40在训练到750epoches的测试准确率达到90.43%.

```
Test Iter:  313/ 313. Data: 0.002s. Batch: 0.005s. Loss: 0.5552. top1: 90.43. top5: 99.44. : 100%|██| 313/313 [00:01<00:00, 193.
Train Epoch: 750/1000. Iter:  104/ 224. LR: 0.0154. Data: 0.331s. Batch: 0.547s. Loss: 0.1896. Loss_x: 0.0002. Loss_u: 0.1893.
```

二、TorchSSL对比

TorchSSL配置环境后运行

```
# labeled 4000
python fixmatch.py --c config/fixmatch/fixmatch_cifar10_4000_0.yaml
# labeled 250
python fixmatch.py --c config/fixmatch/fixmatch_cifar10_250_0.yaml
# labeled 40
python fixmatch.py --c config/fixmatch/fixmatch_cifar10_40_0.yaml
```

开始运行：

```
[2024-06-27 02:26:08,458 INFO] model saved: ./saved_models/fixmatch_cifar10_4000_0/latest_model.pth
/opt/conda/envs/ssl/lib/python3.7/site-packages/sklearn/metrics/_classification.py:1245: UndefinedMetricWarning: Precision is ill-defi
ned and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
[2024-06-27 02:26:10,655 INFO] confusion matrix:
[[0.83  0.087 0.083 0.    0.    0.    0.    0.    0.    0.   ]
 [0.959 0.01  0.031 0.    0.    0.    0.    0.    0.    0.   ]
 [0.909 0.021 0.07  0.    0.    0.    0.    0.    0.    0.   ]
 [0.95  0.019 0.031 0.    0.    0.    0.    0.    0.    0.   ]
 [0.94  0.01  0.05  0.    0.    0.    0.    0.    0.    0.   ]
 [0.923 0.032 0.045 0.    0.    0.    0.    0.    0.    0.   ]
 [0.973 0.    0.027 0.    0.    0.    0.    0.    0.    0.   ]
 [0.944 0.009 0.047 0.    0.    0.    0.    0.    0.    0.   ]
 [0.867 0.065 0.068 0.    0.    0.    0.    0.    0.    0.   ]
 [0.97  0.009 0.021 0.    0.    0.    0.    0.    0.    0.   ]]
[2024-06-27 02:26:10,664 INFO] 0 iteration, USE_EMA: True, {'train/sup_loss': tensor(2.4592, device='cuda:1'), 'train/unsup_loss': ten
sor(0., device='cuda:1'), 'train/total_loss': tensor(2.4592, device='cuda:1'), 'train/mask_ratio': tensor(1., device='cuda:1'), 'lr':
0.029999999999974228, 'train/prefecth_time': 0.7478323364257813, 'train/run_time': 1.0183004150390624, 'eval/loss': tensor(13.4847, de
vice='cuda:1'), 'eval/top-1-acc': 0.091, 'eval/top-5-acc': 0.5013, 'eval/precision': 0.027574393990794376, 'eval/recall': 0.091, 'eval
/F1': 0.027260655222211883, 'eval/AUC': 0.4856872888888888}, BEST_EVAL_ACC: 0.091, at 0 iters
[2024-06-27 02:26:10,766 INFO] model saved: ./saved_models/fixmatch_cifar10_4000_0/model_best.pth
```

□

由于实验参数不完全相同，只对比最终测试结果：

labeled	40	250	4000
FixMatch	90.54	93.06	94.29
TorchSSL	90.58	92.58	94.05

可以看出实现的FixMatch算法与TorchSSL提供的FixMatch训练结果相差不大，TorchSSL使用默认参数没做过多调整，导致准确率略低。在40个样本时测试结果小于正常预期值，原因在于设置的epoches数偏小，训练未完全收敛。后续改进可参考FixMatch源代码中混合精度训练减少舍入误差的问题，以及调整其他参数比如使用余弦退火策略时加入预热阶段，调整batch-size大小观察对准确率的变化等。

三、对比 FixMatch 和 MixMatch

1. MixMatch 和 FixMatch 使用的半监督学习方法不同。MixMatch使用了 Mixup技术将一个样本与另一个随机样本的特征进行混合，并且通过最大化熵损失函数来优化网络，以提高模型的泛化能力；而 FixMatch则使用了自监督学习技术，选择置信度高的无标签数据加入到有标签数据中进行训练网络。
2. MixMatch 的训练过程需要迭代多次才能得到结果，每次迭代都需要对全部无标签数据进行处理；而 FixMatch 只需要迭代一次就能够输出，并且只对部分无标签数据进行处理。